University of Manchester · Alcaldía Mayor de Bogotá ·

AEA-RCT Registry · January 2026 · IRB Approved, University of Manchester

Validación y Calibración de un sistema de Procesamiento de Lenguaje Natural para la clasificación de casos de violencia intrafamiliar

Experimento Aleatorio Controlado · C4-CF Bogotá, Colombia

Natalia Galvis Arias
University of Manchester

Bogotá, Marzo 2026

Motivación: Problema de Política Pública

Por qué esto es importante

- Las llamadas al 123 son el primer **punto de contacto** entre las víctimas de violencia intrafamiliar y el Estado
- La clasificación del riesgo de estas llamadas determina **qué recursos** son asignados y con qué nivel de urgencia
- Evidencia anecdótica sugiere que hay variación sistemática en la clasificación según las características de los operadores, sin embargo **no hay evidencia causal al respecto**

Brecha de conocimiento

¿El género de los operadores puede incidir en la clasificación del riesgo ?

¿Puede la AI ayudar a reducir esos sesgos y otros más?

Motivación: Por qué este estudio es importante

Contribución

1. **Primer estudio experimental** sobre los sesgos en la clasificación de emergencias y el aporte de la AI en su reducción
2. Sistema de Procesamiento de Lenguahe Natural **culturalmente adaptado** para la clasificación de emergencia en Colombia
3. **2×2 diseño factorial** que separa claramente los efectos de la asistencia algorítmica y su incidencia en la reducción de sesgos
4. **Base de conocimiento relavante** para la integración de los servicios de emergencia y los servicios comisariales en Bogotá

Sistema de Clasificación utilizando PLN

- **Objetivo:** Clasificar llamadas de emergencia de la Línea 123 de Bogotá en categorías de riesgo mediante análisis de texto.
- **Dataset:** 376,149 registros (Julio 2021 - Diciembre 2023) con una longitud promedio de 127 caracteres por comentario.
- **Desafíos del PLN:**
  - Alta dimensionalidad de los datos textuales.
  - Severo desequilibrio de clases en los datos de emergencia.
  - Complejidad en los patrones de negación del español.
- **Muestra de Entrenamiento:** 40,000 registros estratificados para asegurar representatividad.

Preprocesamiento y Arquitectura de Riesgo

- **Estandarización Léxica:** Normalización de regionalismos colombianos (ej. "fierro" → arma, "guaro" → alcohol) mediante diccionarios de expertos.
- **Detección de Negación:** Sistema jerárquico que utiliza pesos de confianza ($w_p \in [0.5, 0.9]$) para distinguir entre "no hay armas" y "se reportan armas".
- **Dominios de Riesgo:** 9 categorías con pesos específicos (w_c):
  - **Violencia Grave (5.0):** Riesgo letal extremo.
  - **Armas (4.0):** Presencia de objetos letales.
  - **Víctimas Vulnerables (4.0):** Niños o ancianos involucrados.
- **Factores Multiplicativos:** Ajustes por combinaciones críticas (ej. Armas + Violencia = 1.4x).

Esquema de Clasificación de Categorías de Riesgo

Table: Tabla 1: Esquema de Clasificación de Categorías de Riesgo

Categoría de Riesgo	Peso (w_c)	Términos	Indicadores Urgentes	Prevalencia (%)
Armas	4.0	17	5	8.3
Violencia Física	3.0	15	3	24.7
Violencia Severa	5.0	10	4	3.2
Amenazas	3.0	11	2	15.6
Lesiones	4.0	13	3	12.1
Víctimas Vulnerables	4.0	11	2	9.8
Abuso de Sustancias	2.0	9	2	18.4
Indicadores de Urgencia	3.0	12	—	6.7
Riesgo de Ubicación	3.0	8	2	4.2

Implementación de ML y Resultados

- **Arquitectura del Modelo:** Enfoque de ensamble comparando Random Forest, Gradient Boosting y Regresión Logística.
- **Balanceo de Clases:** Integración de la técnica **SMOTE** para mitigar el sesgo hacia las clases mayoritarias.
- **Modelo Óptimo: Gradient Boosting** con un F1-Score de 0.8146.
- **Métricas Clave:**
  - **Riesgo Alto:** 86.0% de recuperación (Recall), prioritario para efectividad de respuesta.
  - **Riesgo Bajo:** 80.8% de recuperación.
  - **Riesgo Moderado:** 66.8% de recuperación (debido a la ambigüedad en los límites de categoría).

Flujo de Clasificación PLN

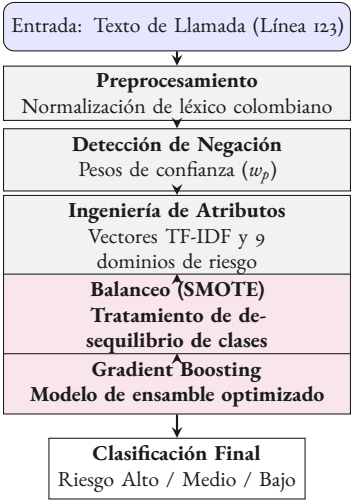

Preguntas de investigación

¿Cómo afecta **el género, la antiguedad (...)** del operador la clasificación del riesgo de violencia?

¿La adopción de herramientas de AI puede mejorar la clasificación del riesgo y reducir los sesgos?

¿La AI tiene **efectos diferenciados** según el género del operador y otras características?

¿Cómo estos efectos varían según **la experiencia**, **el turno de trabajo**, y la **ambiguedad** de la llamada?

Diseño experimental

	Asistencia algorítmica	
Género del operador	**Control**	**Tratamiento**
Mujeres	Cell A	Cell B
Hombres	Cell C	Cell D

Estategia de Identificación

- **Género del operador**: característica natural
- **Asistencia algorítmica** : asignada de manera aleatoria
- Nos permite una clara estimación de:
  - efecto del género
  - efecto de la asistencia algorítmica
  - género $\times$ interacción con la asistencia algorítmica

Diseño experimental: Muestra y resultados

Muestra

- **275 operadores** de la línea de Emergencia 123 de Bogotá C4 (pool: 380)
- Approximadamente **20 llamadas por operador**
- **5,440 total**
- Estratificado por:
  - experiencia
  - turno de trabajo
  - nivel educativo

Resultados principales

1. Precisión de la clasificación
Ajustada a partir del juicio de **217 especialistas** agrupados en **47 paneles de expertos** (Comisarías de Familia)

2. Brecha en la clasificación por género
Diferencia en la clasificación de los casos de alto riesgo entre operadores hombres y mujeres

3. Apoyo algorítimico en la reducción de sesgos
¿Puede la asistencia algorítmica reducir los sesgos en la clasificación del riesgo?

Especificación principal:

$$Y_{ijt} = \alpha + \beta_1 \text{Male}_i + \beta_2 \text{Alg}_i + \beta_3 (\text{Male}_i \times \text{Alg}_i) + \gamma' X_{ijt} + \delta' Z_i + \varepsilon_{ijt}$$

Parametros de interés:

- β_1 Efecto género (control)
- β_2 Efecto de la asistencia algorítmica (mujeres)
- β_3 Efecto diferencial según el género

Controles & Efectos fijos:

- X_{ijt} Características de las llamada (extraídas a partir de PLN)
- Z_i Características del operador

Errores estándar agrupados a nivel de operador. Bootstrap aleatorio (275 agrupaciones)).

Flujo de Experimento Aleatorio Controlado

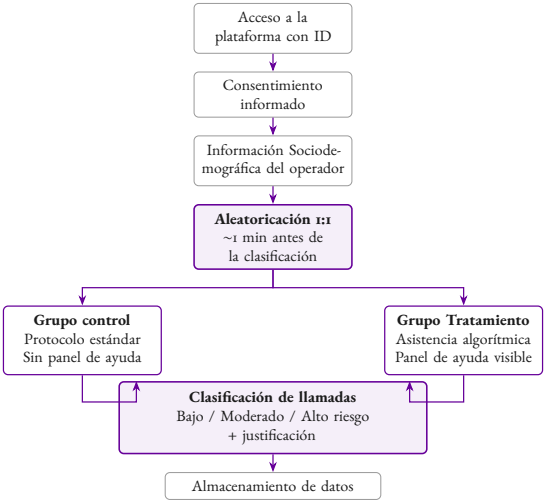

Interface de la asistencia algorítmica

- **Riesgo sugerido:** Categoría visible (Bajo/Mod/Alto) con intervalos de confianza.
- **Características de riesgo:** factores identificados por la AI (e.g., armas, víctimas vulnerables).
- **Advertencias sobre la negación:** Alertas de negación (e.g., "no se registran armas").

Principio fundamental: Human-in-the-Loop

El operador conserva **plena autonomía** en la decisión de clasificación. El algoritmo tiene carácter **informativo**, no vinculante.

Sistema de apoyo en las decisiones de clasificación basado en PLN

El motor del PLN

- **Extracción de características:** >100 marcadores lingüísticos extraídos por llamada en tiempo real.
- **Lógica linguística:** Detección avanzada de la negación en español y análisis sintáctico.
- **Contexto regional** Diccionario entrenado específicamente con conjuntos de datos sobre la violencia intrafamiliar en Colombia.

Validación

Validado contra el "Gold Standard", 47 páneles de expertos compuestos por **217 trabajadores de las comisarías de familia de Bogotá**

Objetivos de fiabilidad

Buscamos una alta fiabilidad entre los evaluadores para minimizar la subjetividad de los operadores

- **Cohen's** $\kappa > 0.80$

Consentimiento informado

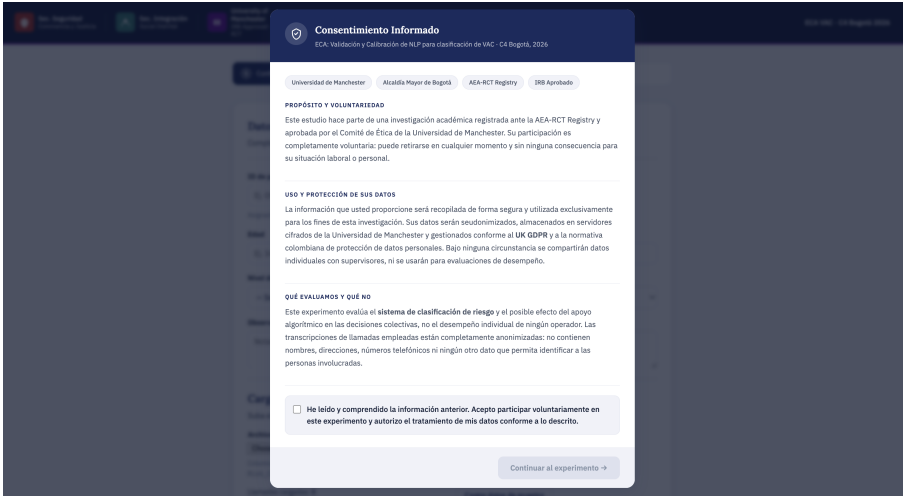

Consentimiento Informado

ECA: Validación y Calibración de NLP para clasificación de VAC · C4 Bogotá, 2026

Universidad de Manchester | Alcaldía Mayor de Bogotá | AEA-RCT Registry | IRB Aprobado

PROPÓSITO Y VOLUNTARIEDAD

Este estudio hace parte de una investigación académica registrada ante la AEA-RCT Registry y aprobada por el Comité de Ética de la Universidad de Manchester. Su participación es completamente voluntaria: puede retirarse en cualquier momento y sin ninguna consecuencia para su situación laboral o personal.

USO Y PROTECCIÓN DE SUS DATOS

La información que usted proporcione será recopilada de forma segura y utilizada exclusivamente para los fines de esta investigación. Sus datos serán seudonimizados, almacenados en servidores cifrados de la Universidad de Manchester y gestionados conforme al **UK GDPR** y a la normativa colombiana de protección de datos personales. Bajo ninguna circunstancia se compartirán datos individuales con supervisores, ni se usarán para evaluaciones de desempeño.

QUÉ EVALUAMOS Y QUÉ NO

Este experimento evalúa el **sistema de clasificación de riesgo** y el posible efecto del apoyo algorítmico en las decisiones colectivas, no el desempeño individual de ningún operador. Las transcripciones de llamadas empleadas están completamente anonimizadas: no contienen nombres, direcciones, números telefónicos ni ningún otro dato que permita identificar a las personas involucradas.

☐ **He leído y comprendido la información anterior. Acepto participar voluntariamente en este experimento y autorizo el tratamiento de mis datos conforme a lo descrito.**

Continuar al experimento →

Características sociodemográficas

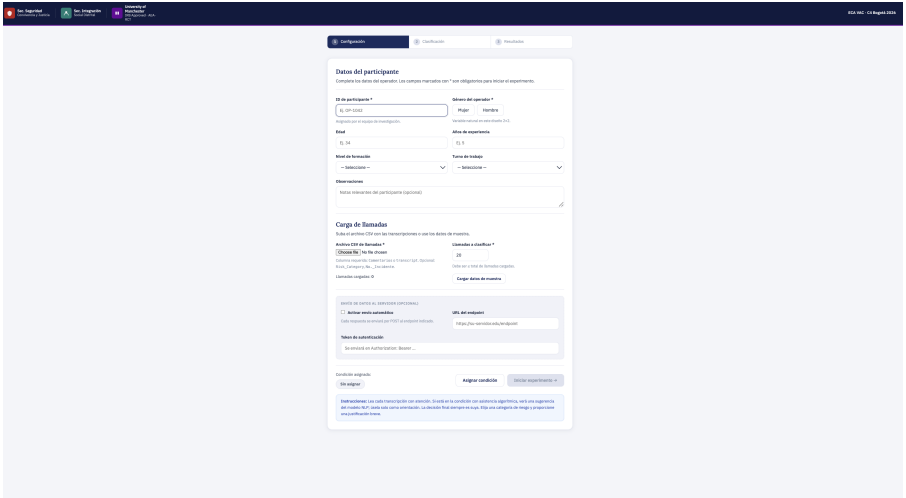

Proceso de clasificación

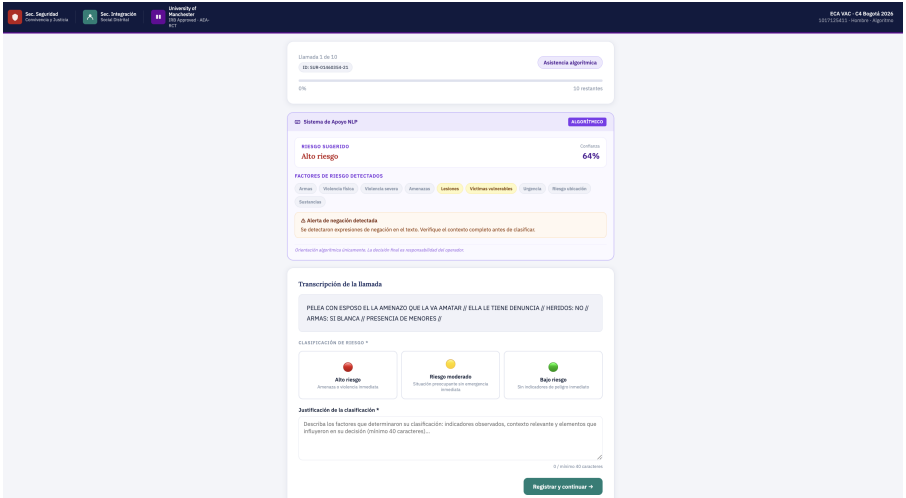

Almacenamiento de datos

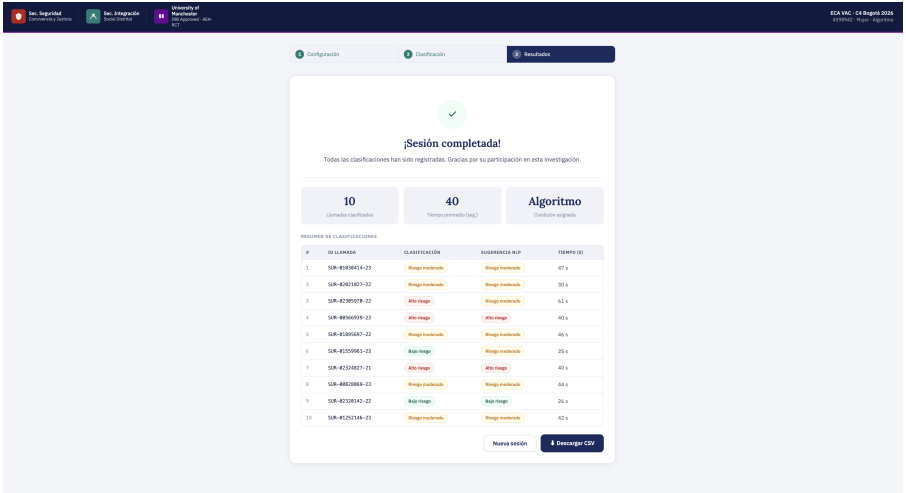

Comisarías de Familia

Operan como el referente especializado

- **217 especialistas** organizados en **47 páneles de expertos**
- Perfil: autoridades públicas en la gestión de casos de violencia intrafamiliar en Bogotá (Comisarios/as, psicólogos/as, y técnicos/as operativos/as)
- Los expertos realizarán una **clasificación a ciegas** de una muestra aleatoria de llamadas
- El concenso de los expertos representa el **gold standard** para medir la precisión de la clasificación del algoritmo

Protocolo de validación de expertos

1. Entrenamiento general en el ejercicio de clasificación y comprensión de la operación algorítimica.
2. **Clasificación ciega** de 20 llamadas: Bajo / Moderado / Alto riesgo
3. El consenso está determinado por **voto por mayoría ponderada o resolución estructurada**
4. Fiabilidad entre evaluadores: **Cohen's** $\kappa > 0.80$

Responsibilidades en el proceso de validación

Carga de validación

- Dos rondas de validación, una en marzo y otra en abril
- **4340 llamadas validadas en las dos rondas**
- Cada llama es independientemente clasificada por cada experto y agregada al panel para su clasificación final
- La clasificación final será integrada al nuevo **benchmark dataset**

Garantías de cumplimiento ético

Todas las llamadas están **completamente anonimizadas y desclasificadas**: no contienen identificadores
Los miembros del panel **desconocen la identidad** de los operadores.
Los datos serán almacenados en **servidores encriptados** de la Universidad de Mánchester.

Plataforma de validación de expertos

La plataforma sigue un flujo lineal de 6 etapas

1. **Configuración del panel:** Pre-aleatorización de los equipos comisarias por rol.
2. **Identificación del participante:** acceso único de cada experto a través de su ID
3. **Clasificación individual:** asignación de riesgo con justificación obligatoria.
4. **Agregación de votos** Visualización de votos ponderados y aplicación automática de la regla de la mayoría.
5. **Adjudicación:** resolución definitiva del Comisario/a en los casos de empate o de resultados dispersos.
6. **Auditoría y exportación de resultados:** trazabilidad completa y extracción de datos en formato CSV

Esta arquitectura operacionaliza el gold-standars utilizando 47 paneles de expertos a través de dos rondas de validación.

Identificación de los participantes

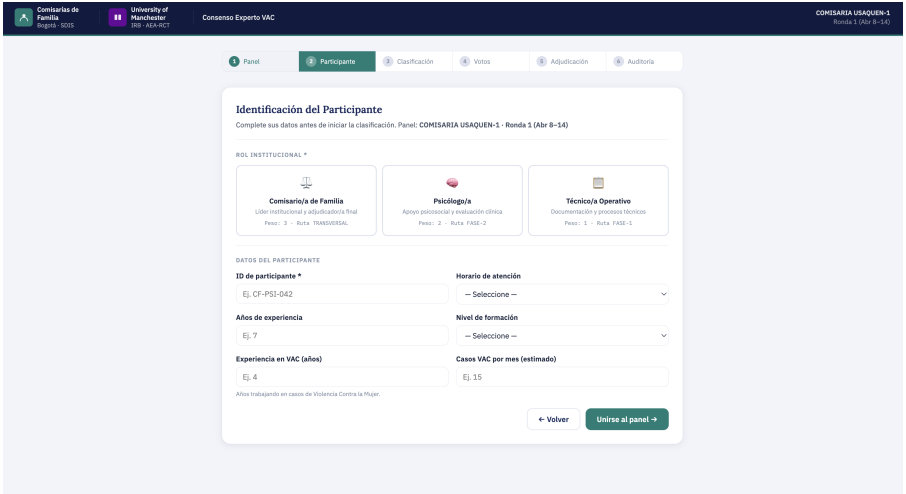

Clasificación individual

Cada miembro del panel clasifica las llamdas de forma **independiente y ciega**.

- Categorías de riesgo:
  - **Alto**
  - **Moderado**
  - **Bajo**
- Se debe escribir una justificación de la clasificación de mínimo **30 caracteres**
- Una vez enviada la respuesta, la plataforma avanza automáticamente a la **siguiente llamada**.

Esta estructura garantiza la independencia del juicio de cada experto antes de que se produzca la agregación a nivel de panel

Clasificación individual

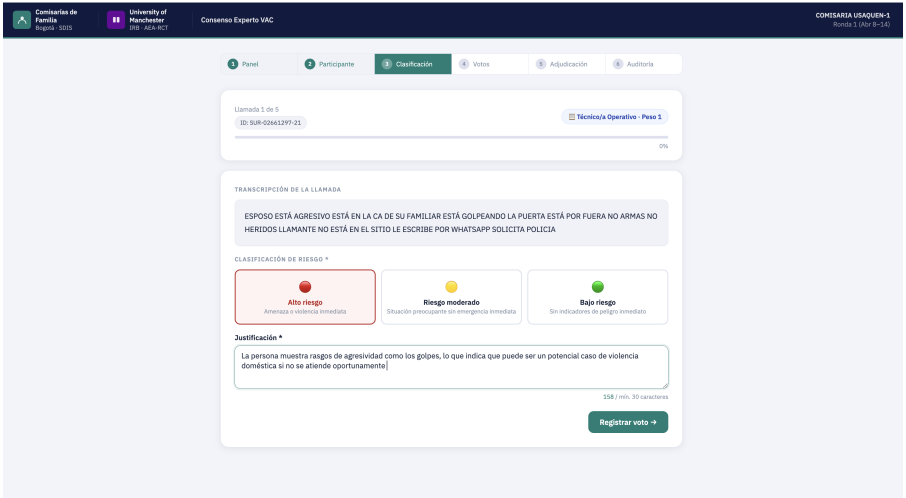

Agregación de votos ponderados

Una vez que se han enviado los votos individuales, la plataforma muestra el recuento global a nivel de panel y asigna una clasificación definitiva.

- Distribución ponderada de los votos
- Visualización final de:
  - Puntuación total
  - Porcentaje por categoría de riesgo
  - Votos individuales a nivel de **rol** and **peso**
  - Estado actual de la decisión

Regla de decisión de disputas:

- Si los votos dan lugar a una **clara mayoría** (> 50%), la plataforma asigna de manera automática el nivel de riesgo
- Si se presenta un **empate** o una **dispersión de los votos**, el sistema habilita el módulo de adjudicación

Agregación de votos ponderados

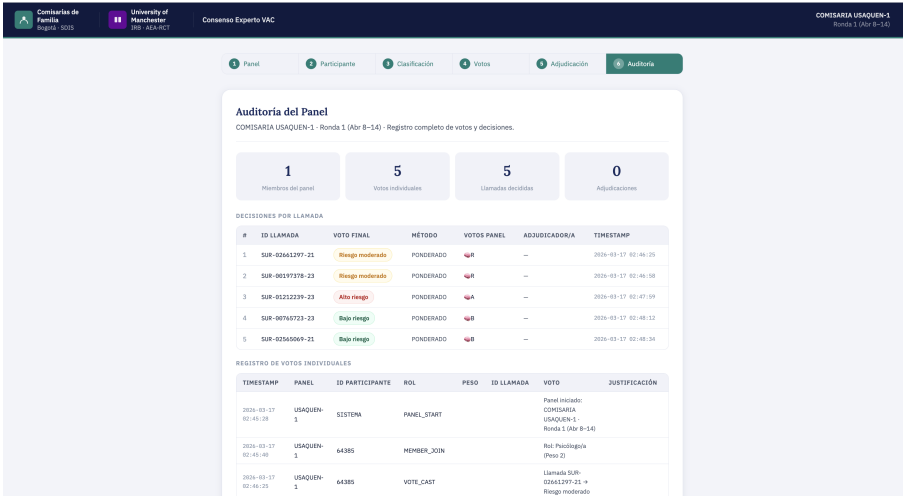

Cómo funciona la adjudicación en casos de disputas

A esta pantalla sólo podrá acceder **el comisario/a de familia** asignado a cada panel.

- Se muestra el resumen de **los votos ponderados**
- Se muestra la **transcripción completa de la llamada**
- Se le permite al Comisario/a tomar una **decisión definitiva**
- Se solicitará una **nota** aclaratoria para efectos de la trazabilidad

Al final el sistema despliega el siguiente mensaje:

ADJUDICADO

De este modo se mantiene una distinción clara entre las decisiones basadas en la mayoría y los casos en los que se ha resuelto un desacuerdo a través de la decisión del comisario/a.

Adjudicación

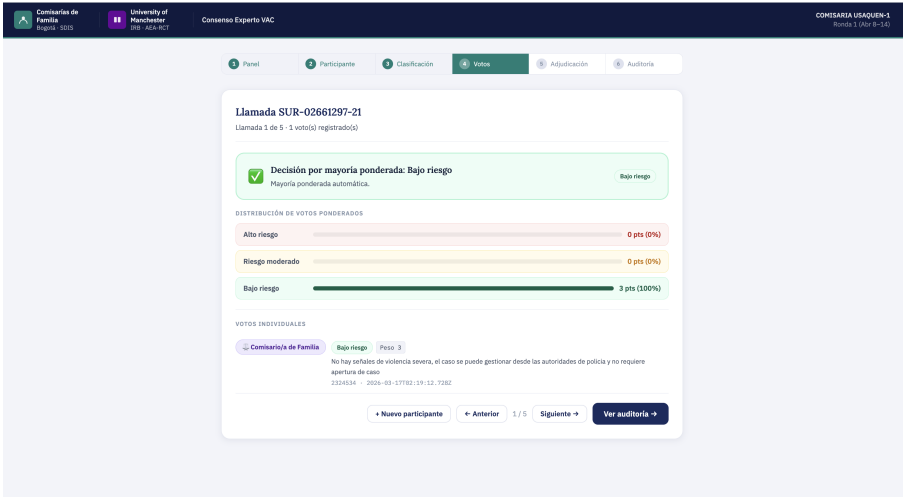

Registro de auditoria y exportación

La pantalla final permite el seguimiento y la extracción de datos individuales

Auditoria por llamada:

- Decisión final
- Método de definición (mayorías / Comisario/a
- Adjudicador (si aplica)
- Fecha y hora

Registro detallado de votos:

- Voto individual
- Rol y peso
- Justificación
- Tiempo de clasificación

La exportación a CSV incluye todas las variables necesarias para el análisis:

- Panel ID
- Votos individuales
- Pesos

Consideraciones éticas

Protección a las víctimas y los llamantes

- Todas la llamadas están **archivadas y anonimizadas**: no hay identificadores visibles
- La información geográfica está limitada a **identificadores generales como barrio**

Protección de los operadores y los equipos comisariales

- **Participación voluntaria** con la opción de retirarse en cualquier momento
- Métricas de clasificación individual **confidenciales** no se comparten con su supervisores u otros jefes jerárquicos
- Monitoreo constante **de la carga cognitiva y el stress**
- Seguimiento **técnico** y apoyo **operativo** durante el estudio.

Protección de datos

Manejo de los datos

- Almacenamiento cifrado en los **servidores de la universidad de Manchéster**
- Acceso restringido **únicamente para los trabajadores/prestadores de servicio** de las Comisarías de Familia y el C4 a través de su ID
- Pleno cumplimiento **de las leyes de protección de datos del Gobierno Colombiano y el Gobierno de UK**
- Mínimo **7 años de almancenamiento de datos** después de la publicación de resultados

Gracias

Preguntas

natalia.galvisarias@manchester.ac.uk

AEA-RCT Registry · January 2026 · IRB UoM Approved